

Entendido perfeitamente! Sem problemas. Vamos recalibrar a rota e focar 100% no mercado e na prática autodidata.

A grande vantagem da Engenharia de Dados é que ela é uma área extremamente técnica e orientada a portfólio. O que realmente conta é a sua capacidade de construir pipelines que funcionem, sejam limpos e escaláveis.

Aqui está a versão corrigida do seu plano de 30 dias, agora totalmente focada em **projetos práticos e documentação de mercado**, sem qualquer vínculo acadêmico:

Meu Objetivo

Dominar os fundamentos de Engenharia de Dados em 30 dias por meio de prática direta, construindo um portfólio técnico focado nas ferramentas mais exigidas pelo mercado (Python, SQL, AWS, dbt e Airflow).

Cronograma Semanal

Semana 1: Modelagem de Dados e Python para Manipulação

- **Foco:** Entender como estruturar tabelas para análise e como manipular dados via código.
- **Distribuição dos tópicos:**
 - **Dias 1 a 3:** Esqueça bancos de dados tradicionais de sistemas (OLTP). Foque em modelagem analítica (OLAP). Estude o conceito de **Star Schema** (Tabelas Fato e Tabelas Dimensão). Entenda por que estruturar os dados assim economiza processamento na nuvem.
 - **Dias 4 a 7:** Python focado em dados. Domine o básico de **Pandas** (leitura de CSVs/JSONs, filtros, joins e agregações). Em seguida, entenda o conceito de processamento distribuído lendo sobre o **PySpark** (como ele lida com dados que não cabem na memória de um computador só).
- **Materiais e Referências:**
 - *Leitura Essencial:* Artigos de blogs técnicos (como Medium/Towards Data Science) sobre "*Star Schema vs Snowflake Schema*".
 - *Prática:* Crie um script Python local que leia um arquivo CSV bagunçado, limpe os dados nulos com Pandas e monte duas tabelas separadas (Fato e Dimensão).

Semana 2: Armazenamento em Nuvem (Data Lakes e Data Warehouses)

- **Foco:** Onde e como salvar dados de forma barata e rápida.
- **Distribuição dos tópicos:**
 - **Dias 8 a 10: Amazon S3 (Data Lake).** Crie uma conta gratuita na AWS. Aprenda a criar "buckets" e entenda o conceito de partições (organizar arquivos em pastas por ano/mes/dia). Entenda a diferença de performance entre arquivos CSV e **Parquet** (colunar).

- **Dias 11 a 14: Google BigQuery ou AWS Redshift (Data Warehouse).** Foque no BigQuery (o plano gratuito é excelente e não pede cartão de crédito de cara). Suba suas tabelas modeladas na Semana 1 para lá e treine consultas SQL analíticas (usando GROUP BY, WINDOW FUNCTIONS e JOINS).
- **Materiais e Referências:**
 - *Documentação:* Guia rápido do Google Cloud sobre "*O que é o BigQuery*".
 - *Prática:* Suba o arquivo que você limpou na Semana 1 para o S3 ou BigQuery e faça consultas para descobrir métricas simples (ex: faturamento por mês).

Semana 3: Pipelines de Dados (ETL / ELT com AWS Glue e dbt)

- **Foco:** Mover os dados da origem para o destino e transformá-los dentro da nuvem.
- **Distribuição dos tópicos:**
 - **Dias 15 a 17:** Entenda a diferença entre ETL (extrai, transforma localmente e carrega) e ELT (extrai, joga o dado bruto na nuvem e transforma lá dentro). Estude o conceito do **AWS Glue** (Data Catalog e Crawlers) para mapear dados automaticamente.
 - **Dias 18 a 21: dbt (data build tool).** Essa ferramenta é o padrão de mercado hoje. Ela permite que você faça transformações no Data Warehouse usando apenas SQL bom e organizado, aplicando testes para ver se o dado não está duplicado ou nulo.
- **Materiais e Referências:**
 - *Curso Gratuito: dbt Fundamentals* (disponível de graça no site oficial da dbt Labs — é o melhor ponto de partida do mercado).

Semana 4: Orquestração com Airflow e Projeto de Portfólio

- **Foco:** Automatizar tudo para rodar sozinho e criar seu portfólio.
- **Distribuição dos tópicos:**
 - **Dias 22 a 25: Apache Airflow.** Entenda o que é uma **DAG** (o desenho do fluxo de tarefas). Aprenda como o Airflow avisa o script de Python para rodar às 2h da manhã, e se der certo, avisa o dbt para rodar às 2h10.
 - **Dias 26 a 30 (O Projeto de Portfólio):** Junte tudo. Crie um projeto no seu GitHub pessoal com o seguinte fluxo:
 1. Um script Python extrai dados de uma API gratuita qualquer.
 2. Salva o arquivo bruto (JSON/CSV) no Amazon S3.
 3. Carrega esses dados no BigQuery.
 4. O dbt limpa e modela esses dados em tabelas de "Fato" e "Dimensão".
 5. O Airflow orquestra esse processo para rodar todo dia.

A Regra de Ouro para as Próximas 4 Semanas: